MyGlico: Arquitetura Técnica

Banco, importação, normalização e proveniência como base confiável para o mapa glicêmico

Core clínico | Dados rastreáveis | Proveniência | Evolução analítica

Foco desta versão

Explicar o recorte técnico que transforma dados heterogêneos em uma base clínica normalizada, rastreável e pronta para análise.

Corte da narrativa

A apresentação reduz repetição e concentra a história em três fluxos: ingestão, qualidade e proveniência.



Felipe Rodrigues Calé

UFRJ • Instituto de Computação

PROBLEMA

Recapitulação do problema

Por que a fundação técnica precisa começar pela qualidade e rastreabilidade do dado

1. Teste

glicemia capilar

2. Diário

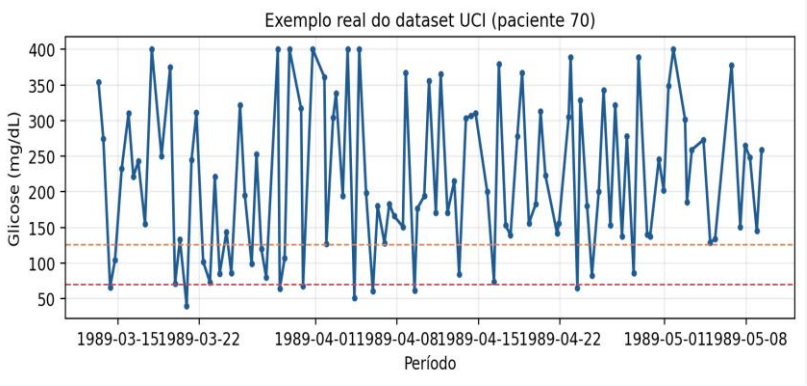
anotação manual

3. Consulta

leitura difícil

4. Decisão

menos apoio clínico



Restrição da disciplina

A base clínica real do HU/UFRJ não cabe no prazo por trâmites burocráticos e éticos. O MVP precisa usar base pública e reproduzível.

Resposta técnica

Validar parser, modelo relacional, normalização e proveniência com o UCI Diabetes.

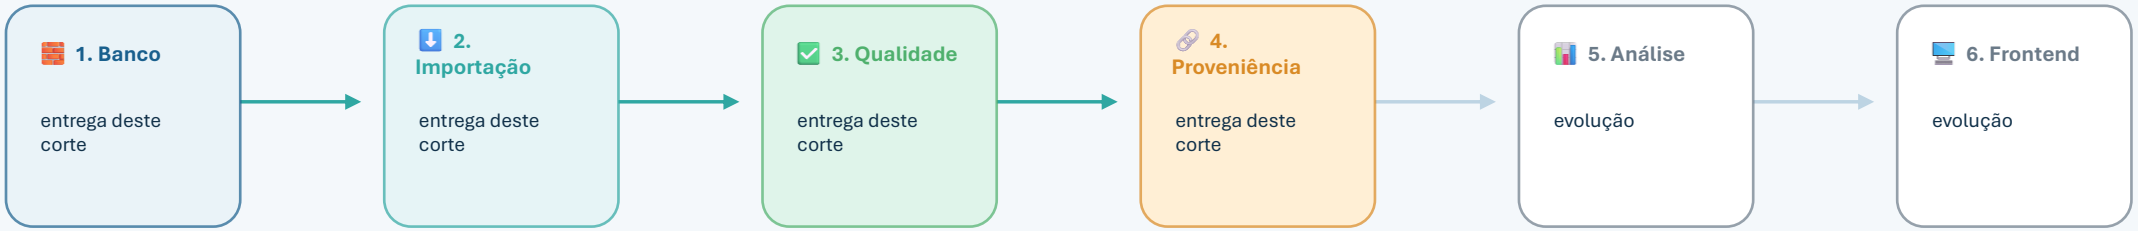
O que muda nesta 2ª rodada

Saímos da escolha do dataset para a arquitetura que garante que cada medição seja explicável.

RECORTE TÉCNICO

Evolução cadenciada do projeto

Primeiro o dado confiável; depois os indicadores e a experiência clínica



Entrega principal deste corte

Banco versionado, importação reprodutível, linha bruta preservada, registro normalizado e vínculo de origem.

Decisão arquitetural

Manter o core clínico limpo e transferir evidências de origem, qualidade, auditoria e hashes para tabelas auxiliares.

Próximos passos

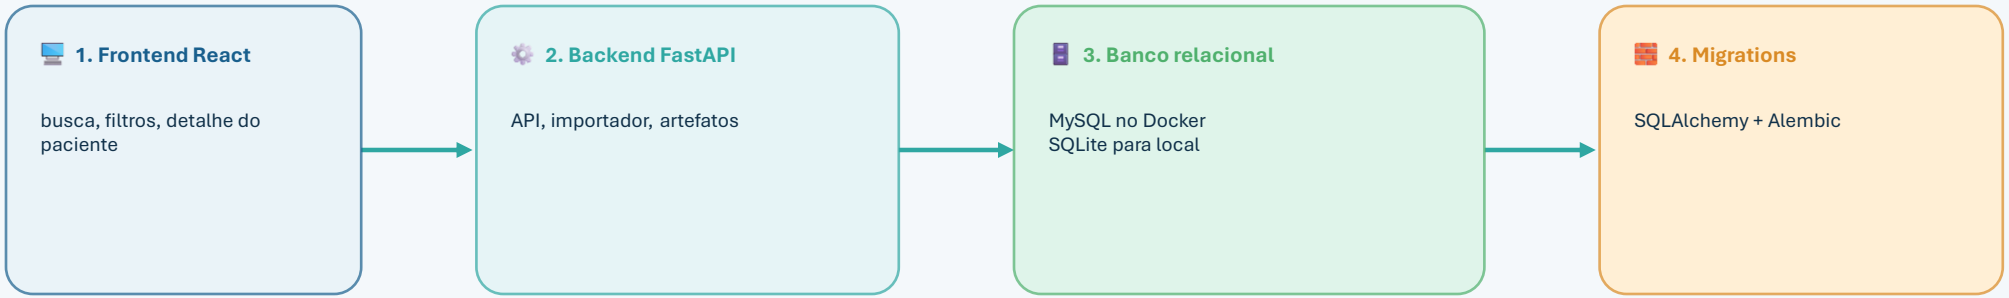
Aplicar indicadores, algoritmos e frontend sobre dados normalizados — não sobre arquivos brutos.

Regra de evolução: o MyGlico não começa por telas; começa por uma base íntegra, auditável e preparada para análise.

ARQUITETURA PROPOSTA

Camadas e responsabilidades

Separação entre interface, API, ingestão, persistência e análise futura



Docker Compose

Sobe db, backend e frontend. O backend aplica migrations e executa o pipeline de bootstrap.

Contrato da API

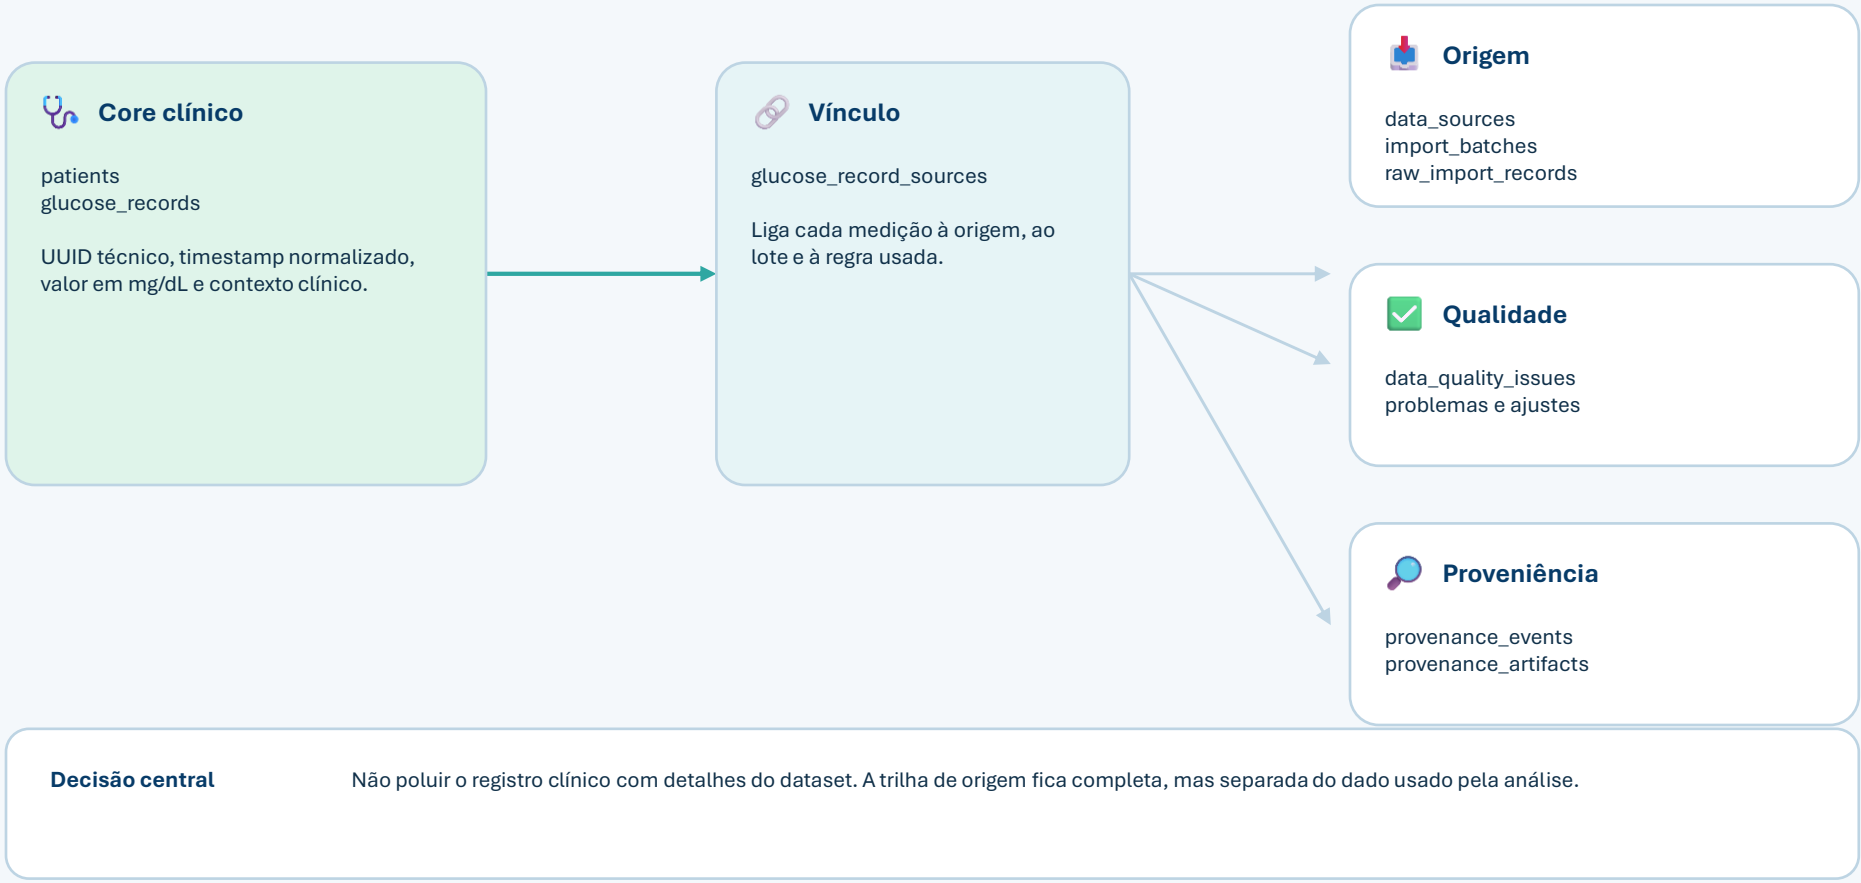
Expõe dados normalizados, indicadores e artefatos sem acoplar o frontend à lógica de importação.

Análise planejada

pandas e scikit-learn processam o core clínico, preservando versão, parâmetros e fingerprint.

Modelo de dados: core clínico + evidências

O dado clínico fica simples; a origem, qualidade e auditoria ficam rastreáveis

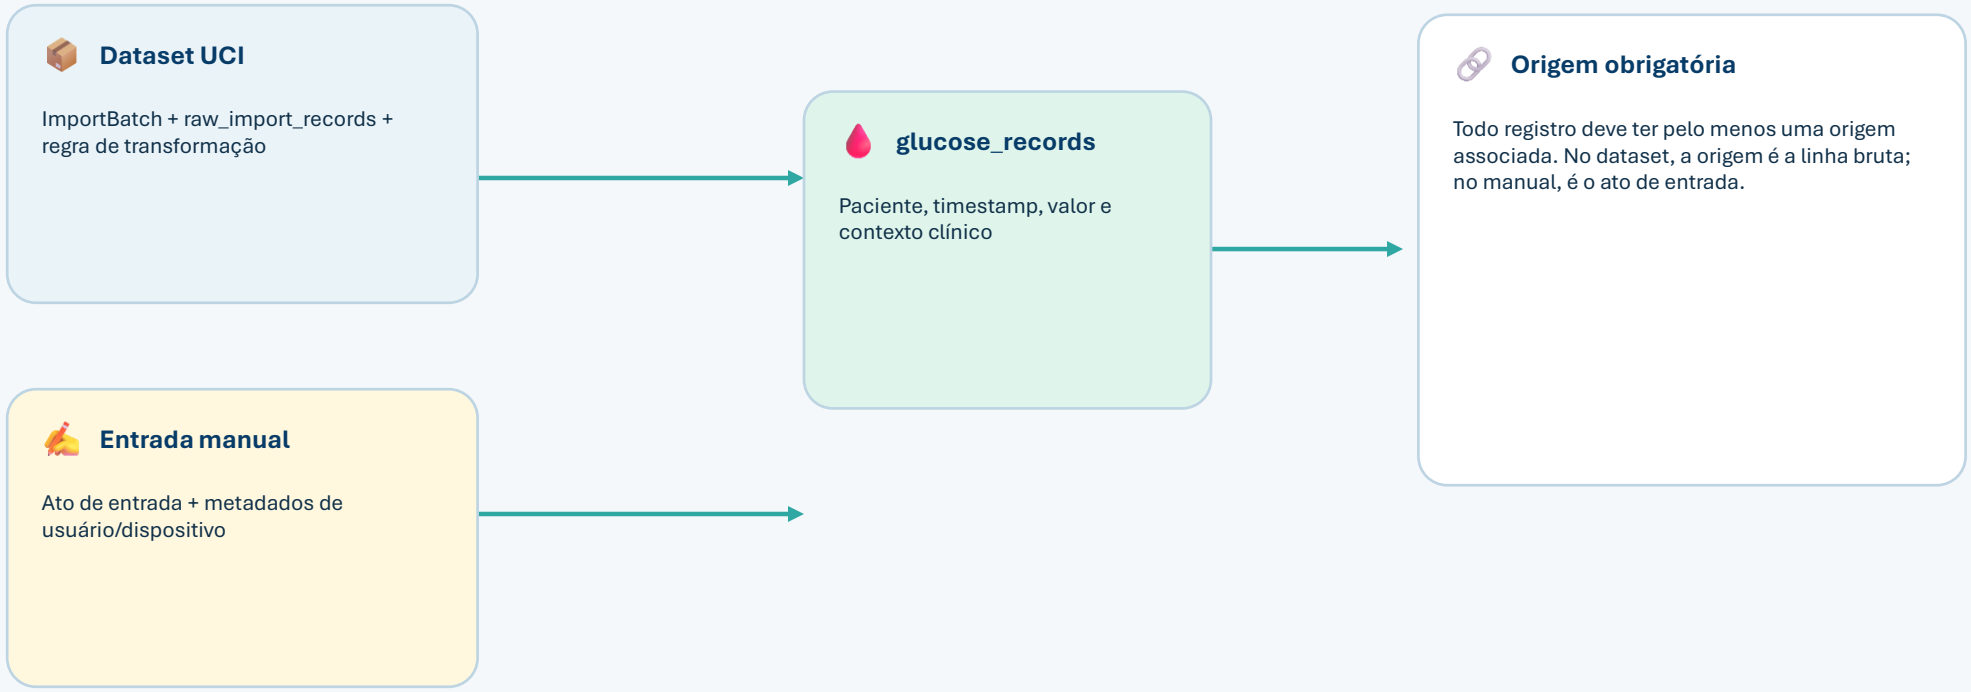


Decisão central Não poluir o registro clínico com detalhes do dataset. A trilha de origem fica completa, mas separada do dado usado pela análise.

DATASET E ENTRADA MANUAL

Um mesmo core para múltiplas origens

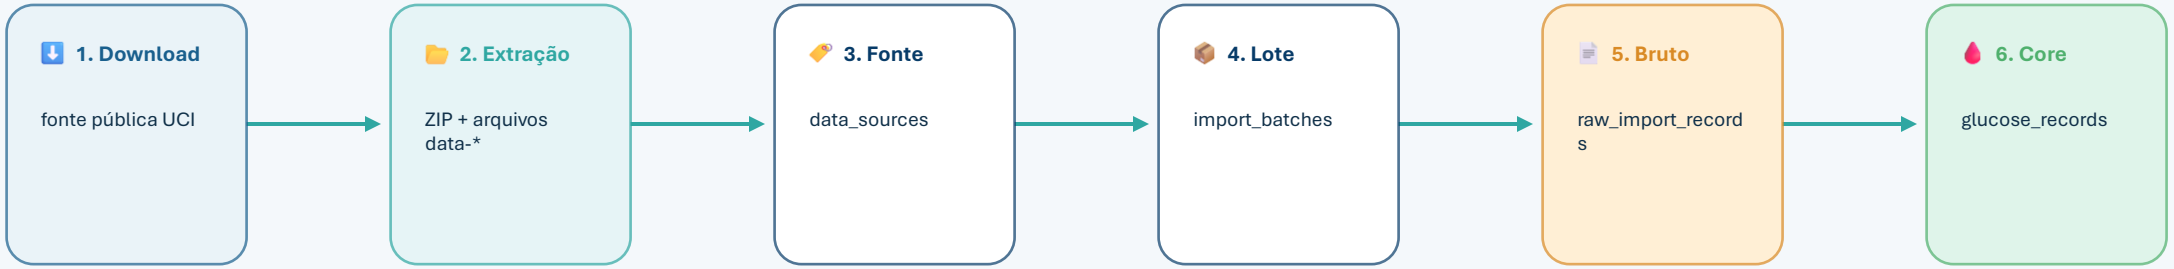
A arquitetura não fica presa ao UCI: dataset e entrada manual convergem para o mesmo núcleo clínico



Resultado: o frontend e os algoritmos podem consumir o mesmo core clínico, independentemente de como o dado entrou no sistema.

Pipeline de importação: do UCI ao core clínico

A carga preserva evidências antes de qualquer transformação relevante



Aquisição

Download, extração e identificação dos arquivos data-* de pacientes.

Registro da carga

DataSource, ImportBatch, status, início/fim, contadores e vínculo paciente ↔ código externo.

Preservação do bruto

Arquivo, linha, payload, data, hora, código e valor originais antes da normalização.

LIMPEZA E NORMALIZAÇÃO

Normalização e qualidade de dados

Transformar arquivo heterogêneo em dado clínico analisável sem esconder imperfeições

🧩 Interpretação do codebook

- códigos UCI → eventos compreensíveis
- somente glicemias viram glucose_records
- contexto clínico: pré/pós refeição ou geral

⏱️ Tratamento de valores e tempo

- valor bruto → número
- data + hora → measured_at
- slots lógicos: 08h, 12h, 18h, 22h

⚠️ Problemas registrados

- linha malformada
- código desconhecido
- duplicidade
- timestamp ajustado

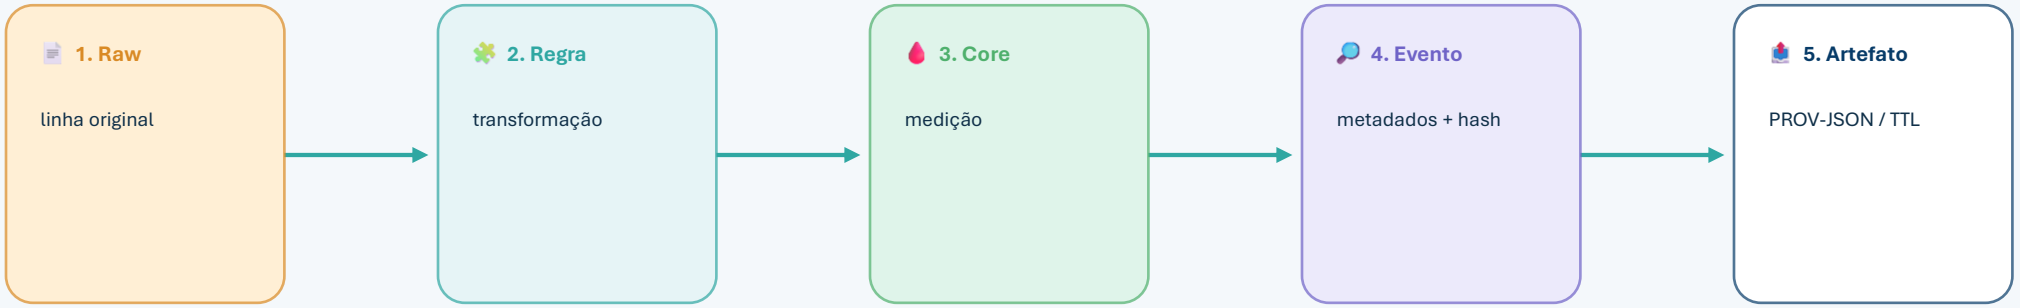
✅ Resultado

O glucose_record guarda apenas o essencial para análise clínica. A explicação de como ele nasceu fica nas tabelas de origem, qualidade e proveniência.

dado clínico limpo | evidência preservada | qualidade auditável | sem descarte silencioso

Proveniência: cada medição conhece sua origem

A trilha conecta dado bruto, transformação, dado normalizado e artefatos auditáveis



Perguntas que o sistema passa a responder

De qual arquivo e linha veio este valor? Qual regra transformou o código? Houve ajuste, duplicidade ou problema de qualidade?

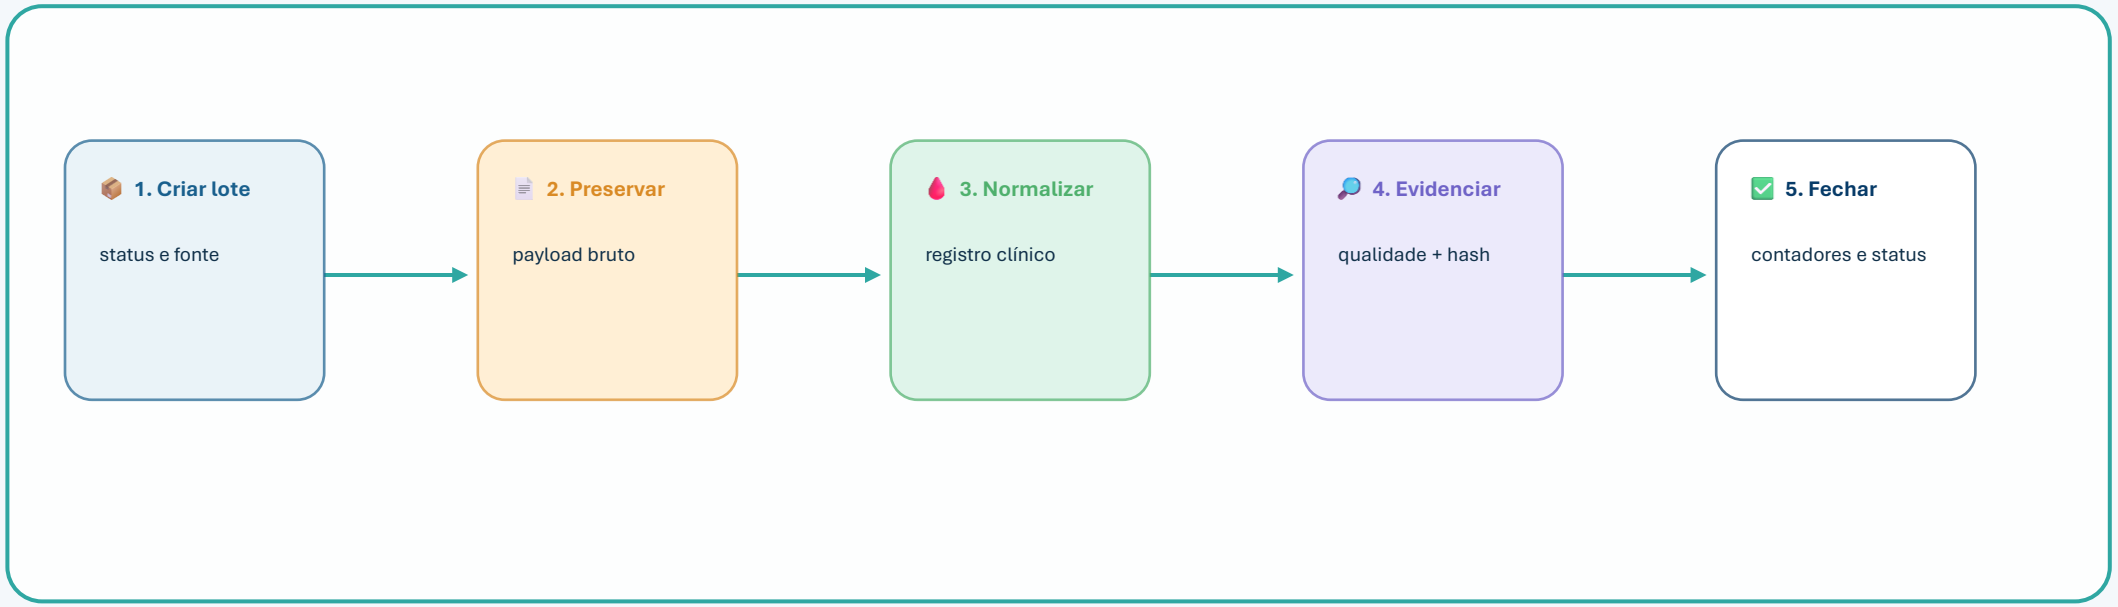
Artefatos derivados

PROV-JSON e PROV-TTL registram formato, caminho, hash e status, preparando o projeto para auditoria e interoperabilidade.

Consistência: importação como unidade auditável

O dado clínico, sua origem e sua proveniência precisam nascer juntos

transação de importação



Garantia 1

Evitar glucose_record sem origem mínima associada.

Garantia 2

Permitir reprocessamento e comparação entre lotes.

Garantia 3

Separar erro de dado bruto de erro do core clínico.

PRÓXIMOS PASSOS

Evolução planejada: análise e acompanhamento

A camada analítica roda sobre glucose_records normalizados e rastreáveis

Core clínico

Registros normalizados + origem consultável

Resumo diário

média, mediana, mínimo, máximo, desvio padrão, CV, contagem e faixas

Sinais avançados

Isolation Forest para dias atípicos
KMeans para perfis de dias

Experiência React

busca, triagem, detalhe do paciente, distribuição por faixa, eventos extremos e explicabilidade

Explicabilidade técnica

Parâmetros, limiares, versão do algoritmo, ambiente, versão do código e fingerprint dos dados de entrada.

Limiar inicial configurável

Hipo < 70 mg/dL; pré-refeição 80–130 mg/dL; pós-refeição/geral até 180 mg/dL.

FECHAMENTO

Estado do recorte e continuidade

A primeira entrega técnica transforma dataset heterogêneo em base clínica confiável

✅ Neste corte

- banco relacional com migrations
- core clínico com UUID
- importador UCI Diabetes
- qualidade + proveniência

🔗 Preparado para

- entrada manual no mesmo core
- múltiplas fontes
- auditoria por origem e lote
- reprocessamento analítico

🚀 Próxima fase

- materializar indicadores
- aplicar modelos analíticos
- evoluir frontend de detalhe
- consultar origem/proveniência

📌 Mensagem final

O MyGlico não apenas importa dados: ele cria uma base normalizada, rastreável e pronta para sustentar análise clínica explicável.

Obrigado!

REFERÊNCIAS

Referências e base técnica

Fontes usadas para fundamentar o recorte de arquitetura e dados

- KAHN, M. Diabetes [Dataset]. UCI Machine Learning Repository. DOI: 10.24432/C5T59G.
- CALÉ, Felipe Rodrigues. MYGLICO: plataforma inteligente para diário de controle glicêmico para pacientes com Diabetes Mellitus. Pré-projeto de mestrado, UFRJ, 2026.
- Base técnica local do projeto MyGlico: modelos SQLAlchemy, migrations Alembic, importador UCI, serviços de proveniência e proposta de camada analítica.
- Tecnologias do recorte: FastAPI, React, Vite, SQLAlchemy, Alembic, MySQL, SQLite, Docker Compose, pandas, scikit-learn, PROV-JSON e PROV-TTL.

Observação

Esta versão consolidou conteúdos repetidos, aproximou a narrativa do modelo anterior e transformou os fluxos técnicos em diagramas mais legíveis.