MyGlico: diário glicêmico inteligente e rastreável para análise de glicemia capilar

Felipe Rodrigues Calé

Instituto de Computação – Universidade Federal do Rio de Janeiro (UFRJ)
Caixa Postal 68.530 – CEP 21941-590 – Rio de Janeiro – RJ – Brasil

cale@ufrj.br

Abstract. *This paper presents MyGlico, an intelligent, low-cost platform to support patients with Diabetes Mellitus who require capillary blood glucose self-monitoring, especially when they do not have access to continuous glucose monitoring sensors. The work evaluates the analytical and semantic layer of the platform as an intelligent diary capable of integrating recorded or imported measurements, processing them in a standardized way and transforming them into traceable daily indicators based on published clinical thresholds, with potential to support interpretation by healthcare teams. The experiments used the public, de-identified UCI Diabetes dataset: the data were imported, assessed for quality, normalized with temporal context and converted into daily indicators aligned with American Diabetes Association thresholds, applying Isolation Forest for atypical-day flagging and K-Means for daily-profile grouping. The processed base contains 70 pseudonymized patients, 29,297 raw records and 13,531 normalized glucose measurements, generating 3,860 daily indicators, 196 data quality issues and 222 flagged atypical days. Import and analysis provenance is recorded as PROV-JSON/PROV-TTL artifacts, and the relational core can be published as RDF through a declarative R2RML mapping. The validation covers computational consistency, indicator generation and end-to-end traceability; clinical validation with patients or health professionals was not part of this study. Preliminary results indicate that standardization, traceability and analytics enrich the glycemic diary, offering a more auditable and organized view of the patient's evolution.*

Resumo. *Este artigo apresenta o MyGlico, uma plataforma inteligente e de baixo custo para apoiar pacientes com Diabetes Mellitus que necessitam de automonitoramento por glicemia capilar, especialmente quando não possuem acesso aos sensores de monitoramento contínuo. O trabalho avalia a camada analítica e semântica da plataforma como um diário inteligente capaz de integrar medições registradas ou importadas, tratá-las de forma padronizada e transformá-las em indicadores diários rastreáveis, baseados em limiares clínicos publicados, com potencial para apoiar a interpretação pelas equipes de saúde. Os experimentos utilizaram o dataset público e desidentificado UCI Diabetes: os dados foram importados, avaliados quanto à qualidade, normalizados com contexto temporal e convertidos em indicadores diários alinhados aos limiares da American Diabetes Association, com aplicação de Isolation Forest para sinalização de dias atípicos e K-Means para agrupamento de perfis diários. A base processada contém 70 pacientes*

pseudonimizados, 29.297 registros brutos e 13.531 medições glicêmicas normalizadas, gerando 3.860 indicadores diários, 196 apontamentos de qualidade e 222 dias atípicos sinalizados. A proveniência da importação e da análise é registrada em artefatos PROV-JSON/PROV-TTL, e o núcleo relacional pode ser publicado como RDF por meio de um mapeamento R2RML declarativo. A validação cobre a consistência computacional, a geração dos indicadores e a rastreabilidade de ponta a ponta; a validação clínica com pacientes ou profissionais de saúde não fez parte deste estudo. Os resultados preliminares indicam que a padronização, a rastreabilidade e as análises enriquecem o diário glicêmico, oferecendo um monitoramento mais auditável e organizado da evolução do paciente.

Palavras-chave: Diabetes mellitus; Glicemia capilar; Ciência de Dados; Proveniência de Dados; RDF; Saúde Digital

1. Introdução

O diabetes mellitus é uma doença crônica em que o organismo não produz insulina em quantidade suficiente ou não consegue usá-la de forma adequada, o que faz os níveis de glicose no sangue oscilarem de maneira difícil de prever ("Plano de Reorganização da Atenção à Hipertensão Arterial e ao Diabetes Mellitus", 2001). Para manter essas oscilações sob controle, o paciente precisa acompanhar regularmente a própria glicemia, e na maior parte dos casos esse acompanhamento é feito pelo automonitoramento da glicemia capilar, cujas medições orientam o ajuste da medicação e as decisões da equipe de saúde (DE OLIVEIRA, BARBOSA, *et al.*, 2018). O Brasil ocupa atualmente a 6ª posição entre os países com maior número de pessoas com diabetes, cerca de 16,6 milhões de indivíduos, com estimativas que apontam para 24 milhões de casos até 2050 (ATLA DO DIABETES DA FEDERAÇÃO INTERNACIONAL DE DIABETES, 2025).

Existe a alternativa dos sensores de monitoramento contínuo de glicose (SILVA, NEGRI, *et al.*, 2024), mas seu uso ainda é limitado pelo alto custo de aquisição e pela não incorporação da tecnologia ao Sistema Único de Saúde (SUS), uma vez que a Comissão Nacional de Incorporação de Tecnologias no Sistema Único de Saúde (CONITEC) não recomendou sua adoção para o monitoramento da glicose em pacientes com diabetes mellitus (CONITEC, 2024). Avanços legislativos recentes sinalizam uma ampliação desse acesso, como a Lei nº 15.439/2026, que assegura às pessoas com diabetes tipo 1 o acesso a medicamentos e aos insumos necessários à administração de insulina e ao monitoramento glicêmico (BRASIL, 2026). Na prática, porém, a glicemia capilar anotada manualmente segue sendo a forma recorrente de acompanhamento para muitos pacientes: coleta-se uma gota de sangue em um glicosímetro, que afere o nível de glicose, e cada teste precisa ser anotado com data, horário e as informações de contexto que o médico julgar necessárias.

Na ausência de um formato padronizado, essas anotações tendem a se dispersar em cadernos, planilhas e arquivos não estruturados, gerando dados esparsos, incompletos e de difícil interpretação pelas equipes de saúde (SELVAN, THUKRAL, *et al.*, 2017). Essa limitação afeta não só a leitura do diário, mas também a avaliação médica e a tomada de decisão sobre o tratamento. Por isso, o problema é tratado aqui como uma questão de organização, qualidade e rastreabilidade dos registros glicêmicos.

Nesse contexto, este trabalho avalia a camada analítica e semântica do MyGlico como um diário glicêmico inteligente e de baixo custo, capaz de integrar medições registradas manualmente ou importadas, tratá-las de forma padronizada e transformá-las em indicadores diários rastreáveis, baseados em critérios clínicos publicados, com potencial para apoiar a interpretação pelas equipes de saúde. Para validar essa camada sem depender da coleta de dados reais ou da geração de dados sintéticos, o experimento utiliza um conjunto de dados público e desidentificado disponibilizado pelo *UCI Machine Learning Repository*, o UCI Diabetes (KAHN, 1994), empregado conforme as condições de uso informadas pela fonte. Os arquivos do dataset foram importados, avaliados quanto à qualidade, normalizados com contexto temporal e convertidos em indicadores diários, com a proveniência registrada em cada etapa.

2. Trabalhos Relacionados

O automonitoramento glicêmico apoiado por software é um tema consolidado. Revisões sobre aplicativos móveis de autogestão do diabetes mostram que a maioria oferece registro de glicemia, lembretes e gráficos, mas frequentemente carece de padronização dos dados, de mecanismos de qualidade e de rastreabilidade das transformações aplicadas (EL-GAYAR, TIMSINA, *et al.*, 2013). O relatório de consenso da *European Association for the Study of Diabetes* (EASD) e da *American Diabetes Association* (ADA) sobre tecnologias digitais em diabetes reforça esse ponto ao destacar a necessidade de validade clínica e de transparência nos aplicativos, requisitos ainda pouco atendidos pelo mercado (FLEMING, PETRIE, *et al.*, 2020). O MyGlico atua justamente nessa lacuna, priorizando a organização, a padronização e a rastreabilidade das medições capilares.

No uso de aprendizado de máquina sobre perfis glicêmicos, o trabalho de Woldaregay et al. sistematiza a aplicação de classificação de padrões e detecção de anomalias a dados de glicemia em diabetes tipo 1, incluindo métodos não supervisionados semelhantes aos adotados no Myglico (WOLDAREGAY, ÅRSAND, *et al.*, 2019). Revisões sobre inteligência artificial para gestão do diabetes descrevem abordagens variadas de apoio à decisão, que vão da predição glicêmica à recomendação terapêutica (CONTRERAS, VEHI, 2018). Neste recorte, o uso de aprendizado de máquina é mais restrito: o *Isolation Forest* e o *K-Means* são aplicados como sinais exploratórios sobre os indicadores diários, sem pretensão de predição ou de recomendação clínica.

O trabalho mais próximo na articulação entre glicemia e web semântica é o do projeto D1namo, de Calbimonte et al., que representa eventos glicêmicos em RDF a partir de dados de sensores vestíveis, ligando camadas do dado bruto ao evento complexo e processando-as com um motor de RDF *Stream Processing* (CALBIMONTE, RANVIER, *et al.*, 2017). O escopo, no entanto, é diferente: o D1namo parte de sensores contínuos e não invasivos, enquanto o MyGlico atende ao automonitoramento por glicemia capilar registrado manualmente, priorizando a qualidade dos dados, a proveniência e a rastreabilidade das medições.

Na dimensão de proveniência e publicação semântica em saúde, Curcin et al. mostram que registrar a proveniência dos dados de forma interoperável na pesquisa biomédica é essencial para a reprodutibilidade e a auditoria, oferecendo modelos que inspiram o uso do PROV neste trabalho (CURCIN, MILES, *et al.*, 2014). No plano da

representação, a triplificação de dados relacionais em RDF por meio de mapeamentos R2RML (DAS, SUNDARA, *et al.*, 2012) e ontologias de domínio permite publicar registros clínicos como dados interligados e consultáveis por SPARQL (HARRIS, SEABORNE, 2013). O MyGlico combina essas duas frentes, a proveniência PROV e a publicação declarativa em RDF, sobre um diário de glicemia capilar, articulando qualidade de dados, indicadores analíticos e rastreabilidade em uma única prova de conceito, o que o distingue tanto do D1namo, centrado na aquisição por sensores, quanto dos aplicativos de registro e dos estudos de aprendizado de máquina que tratam esses aspectos isoladamente.

3. Proposta e Escopo do Recorte Analítico

A proposta deste recorte não é cobrir toda a plataforma do projeto, mas avaliar a camada analítica e semântica do MyGlico como um diário digital de mapa glicêmico. Embora a medição capilar seja amplamente utilizada no acompanhamento da doença, o valor clínico desses registros depende da capacidade de organizá-los de forma temporal, contextual e rastreável. Por isso, o MyGlico não é tratado apenas como uma interface de registro, mas como uma plataforma capaz de converter medições pontuais em indicadores estruturados para apoio à interpretação clínica.

A prova de conceito foi estruturada com um backend em FastAPI, um núcleo persistente baseado em SQLAlchemy com migrações Alembic sobre MySQL, uma camada analítica implementada com pandas e scikit-learn, mecanismos de proveniência em PROV-JSON e PROV-TTL e uma interface web em React com suporte a múltiplos idiomas, como português, inglês e espanhol, tanto na navegação quanto no relatório clínico do paciente exportável em PDF. A representação semântica do núcleo relacional é declarada por um mapeamento R2RML e por uma ontologia OWL local, o vocabulário MYGV; isso permite que o grafo RDF (CYGANIAK, WOOD, *et al.*, 2014) seja materializado por qualquer processador R2RML e consultado por SPARQL, sem duplicar a lógica da aplicação.

O trabalho contribui em três frentes que se encadeiam ao longo do pipeline: a organização do diário em uma base clínica rastreável, que modela pacientes, fontes de dados, lotes de importação, registros brutos, medições glicêmicas normalizadas, vínculos entre registro original e registro processado, eventos de proveniência e indicadores diários; a derivação de indicadores clínicos diários, com detecção de dias atípicos e agrupamento de perfis; e o registro da proveniência de ponta a ponta, que permite refazer o caminho do indicador derivado até a linha exata do arquivo de origem.

No MyGlico, a proveniência dos dados é expressa segundo o modelo PROV do W3C (LEBO, SAHOO, *et al.*, 2013). A plataforma registra a origem dos dados, o lote de importação, o arquivo e a linha de origem, a regra de transformação aplicada, metadados de qualidade do timestamp e hashes de conteúdo das entradas e saídas analíticas. Essa estrutura existe por uma razão prática: a confiabilidade de um indicador depende da capacidade de verificar de qual registro ele foi derivado e por quais transformações esse registro passou.

É importante delimitar a fronteira entre apoio computacional e decisão clínica. O MyGlico não pretende substituir julgamento profissional nem recomendar condutas terapêuticas; o que ele estrutura são os dados, de forma que equipe de saúde e

pesquisador consigam acompanhar a evolução glicêmica do paciente com mais transparência e auditabilidade.

4. Metodologia

O experimento parte de uma pergunta central: os registros semiestruturados de um diário glicêmico conseguem ser transformados em indicadores clínicos rastreáveis, mantendo visível o caminho entre o dado bruto e o indicador derivado? Para respondê-la, o fluxo executado, resumido na Figura 1, foi: importação dos arquivos do UCI Diabetes, avaliação de qualidade, normalização das medições glicêmicas, cálculo dos indicadores diários, aplicação dos algoritmos de detecção de anomalias e de agrupamento e geração dos artefatos de proveniência, até chegar à interface web, ao relatório clínico em PDF e à publicação semântica em RDF.

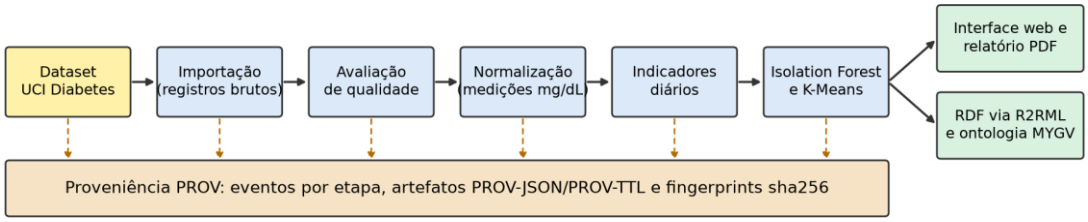


Figura 1. Visão geral do pipeline do MyGlico, da importação do dataset à interface e à publicação semântica, com a proveniência registrada em cada etapa.

O dataset é composto por arquivos de acompanhamento ambulatorial com registros temporais de glicemia, insulina, alimentação, exercício e eventos especiais, no formato de quatro campos por linha: data, horário, código do evento e valor associado. Durante a importação, a plataforma inspeciona a conformidade das linhas, a validade formal dos *timestamps*, a presença de duplicidades, a existência de códigos desconhecidos e a necessidade de coerção de valores numéricos ou datas; cada ocorrência relevante é registrada como apontamento de qualidade, com severidade, tipo do problema, descrição e regra de validação associada. Os registros originais são preservados integralmente antes da geração das medições normalizadas.

Na normalização, datas e horários são convertidos para objetos temporais, os códigos do dataset são mapeados para tipos e subtipos de evento e os registros de glicose são convertidos em medições em mg/dL com rótulos de contexto, como pré-café da manhã, pós-almoço ou pré-jantar. Horários alinhados a janelas canônicas, como 08h00, 12h00, 18h00 e 22h00, são apenas marcados como possíveis slots lógicos de diários em papel, sem substituir o horário registrado.

A etapa analítica é executada sobre as medições normalizadas com a biblioteca pandas. Cada medição recebe classificações de hipoglicemia, faixa alvo e hiperglicemia calculadas em função do contexto: 80 a 130 mg/dL para contextos pré-prandiais, valores inferiores a 180 mg/dL para contextos pós-prandiais e o intervalo operacional de 70 a 180 mg/dL para medições sem contexto, sempre com hipoglicemia definida abaixo de 70 mg/dL, seguindo as recomendações da ADA para a maioria dos adultos não gestantes com diabetes (AMERICAN DIABETES ASSOCIATION PROFESSIONAL PRACTICE COMMITTEE FOR DIABETES, BAJAJ, *et al.*, 2026) . Os registros são então agrupados por paciente e data, e cada dia origina um vetor de indicadores com quantidade de eventos, média, mediana, mínimo, máximo, desvio-padrão, coeficiente de

variação, percentuais de hipoglicemia, faixa e hiperglicemia, desempenho em faixa nos períodos pré e pós-prandial e contagens de eventos extremos.

Sobre os vetores diários de cada paciente são aplicados dois algoritmos não supervisionados da biblioteca scikit-learn, executados pela rotina daily_glycemic_summary em sua versão v2. O Isolation Forest é acionado quando o paciente possui pelo menos cinco dias de indicadores; ele recebe a média, o desvio-padrão, os percentuais de hipoglicemia e hiperglicemia e a quantidade de eventos do dia, com contaminação ajustada entre 5% e 20% em função do número de dias observados, e atribui a cada dia um escore que sinaliza os dias mais afastados do padrão do próprio paciente. O K-Means, acionado a partir de três dias, agrupa os mesmos vetores em até três grupos, com o número de grupos limitado pela quantidade de dias disponíveis. As variáveis são fornecidas aos algoritmos em suas escalas originais, sem padronização prévia; como média glicêmica, percentuais e contagem de eventos possuem ordens de grandeza distintas, essa escolha favorece as variáveis de maior magnitude e constitui uma decisão de projeto desta versão, cujo refinamento está previsto futuramente. Ambos os algoritmos usam semente aleatória fixa, e cada execução é persistida com os parâmetros utilizados, as versões das bibliotecas, a revisão do código-fonte e os fingerprints sha256 de entrada e saída, o que permite reproduzir e auditar a análise.

A proveniência acompanha todas as etapas. Cada importação cria uma fonte de dados, um lote de importação, registros brutos, vínculos pseudonimizados entre pacientes e códigos externos e objetos de origem que conectam cada medição ao registro bruto correspondente, e cada medição normalizada gera um evento de proveniência que a associa ao seu registro de origem. Os artefatos de proveniência são grafos PROV-O em que agentes, atividades e entidades se conectam pelas relações used, wasGeneratedBy, wasDerivedFrom e wasAssociatedWith; eles são serializados em PROV-JSON e PROV-TTL, registrados na base com hash de conteúdo sha256 e renderizados como diagramas simplificados por um script que organiza os nós em camadas de insumos, agentes, atividades e saídas, com os identificadores completos e os hashes preservados nos arquivos versionados no repositório. O objetivo é o mesmo que motivou o diário desde o início: permitir refazer, a qualquer momento, o caminho do indicador publicado até a linha exata do arquivo de origem.

A validação comparou as contagens de registros em cada etapa, a materialização das métricas correntes, a presença dos eventos de proveniência e a geração dos artefatos derivados, além da apresentação dos indicadores no front-end e no relatório clínico em PDF. Além disso, uma demonstração pública da plataforma foi implantada em **https://myglico.vercel.app**, na qual o *frontend* e a API compartilham o mesmo domínio e o banco MySQL gerenciado é o único serviço externo, permitindo verificar o comportamento da prova de conceito fora do ambiente local.

5. Resultados e Discussão

A execução local da prova de conceito percorreu o fluxo completo de ingestão, normalização, análise e persistência dos indicadores. A base importada contém 70 pacientes pseudonimizados, 29.297 registros brutos preservados e 13.531 medições glicêmicas normalizadas, e a execução analítica mais recente produziu 3.860

indicadores diários, todos materializados também como métricas correntes. A Tabela 1 apresenta o resumo quantitativo da base processada.

Tabela 1. Resumo quantitativo da base processada e dos artefatos gerados pelo MyGlico.

Item	Resultado
Pacientes pseudonimizados	70
Registros brutos importados	29.297
Medições glicêmicas normalizadas	13.531
Indicadores diários gerados	3.860
Apontamentos de qualidade de dados	196
Dias atípicos identificados	222
Eventos de proveniência	13.532
Artefatos de proveniência registrados	4

No processo de avaliação da qualidade dos dados, foram registrados 196 apontamentos. As ocorrências envolveram códigos desconhecidos, registros de *placeholder* divididos, possível alinhamento a slots lógicos, coerção de *timestamps*, coerção de valores numéricos e duplicidades. Esses apontamentos não foram tratados como falhas impeditivas; eles ajudam a explicar por que a preservação do registro original é essencial em dados derivados de fontes semiestruturadas. A etapa de limpeza, portanto, não corrige silenciosamente os dados: ela documenta as condições que podem interferir na interpretação posterior.

A distribuição contextual das medições, apresentada na Tabela 2, ajuda a caracterizar o dataset. Das 13.531 medições, 8.691 tinham horário efetivamente registrado e 4.840 foram marcadas como alinhadas a slots lógicos, indicando a coexistência de horários reais e horários padronizados de preenchimento. Essa distinção é importante para a análise de séries temporais glicêmicas, pois separa medições temporizadas de registros que podem representar horários padronizados de diário em papel.

Tabela 2. Distribuição das medições glicêmicas normalizadas por contexto temporal.

Contexto temporal	Total
Pré-café da manhã	3.518
Pré-jantar	3.160
Sem contexto especificado	2.873
Pré-almoço	2.771
Pré-lanche	904
Pós-jantar	219
Pós-almoço	66
Pós-café da manhã	20

Os indicadores gerados pela camada analítica mostram a transformação dos registros capilares em medidas sintéticas de acompanhamento. Considerando os indicadores diários da execução analisada, a média glicêmica agregada foi de aproximadamente 161,5 mg/dL, com média de 11,7% de eventos em hipoglicemia, 30,2% em faixa alvo e 54,9% em hiperglicemia, e a rotina de detecção sinalizou 222 dias atípicos. A soma dos três percentuais médios não alcança 100% por duas razões: as três faixas não são exaustivas, pois, em contextos pré-prandiais, uma medição entre 70 e 80 mg/dL não é classificada como hipoglicemia, faixa alvo nem hiperglicemia, ficando fora das três categorias; e cada percentual é calculado por dia e depois a média entre os dias é obtida, o que introduz pequenas diferenças de arredondamento. Esses valores não devem ser interpretados como estimativas epidemiológicas, pois derivam de um dataset público utilizado para validação computacional; eles demonstram que a plataforma consegue sintetizar, a partir de medições pontuais, indicadores baseados em critérios clínicos publicados, cuja utilidade ainda requer avaliação com profissionais de saúde.

Os resultados de proveniência reforçam a rastreabilidade do processo. A base local registra 13.532 eventos de proveniência: um evento de normalização para cada uma das 13.531 medições, que a liga ao respectivo registro bruto, mais um evento correspondente à execução analítica que gerou os indicadores diários. Estão associados à essa execução quatro artefatos derivados, todos registrados com *hash* de conteúdo sha256: a proveniência da importação em JSON e TTL e a proveniência da análise em JSON e TTL. Os diagramas PROV-O renderizados a partir desses artefatos, apresentados de forma simplificada nas Figuras 2 e 3, explicitam graficamente os agentes, as atividades e as relações de derivação da importação e da análise. Assim, o pipeline não entrega apenas o indicador final: ele mantém visível a passagem do dado bruto para a medição normalizada e desta para o indicador analítico, preservando a relação entre fonte, transformação, execução e resultado.

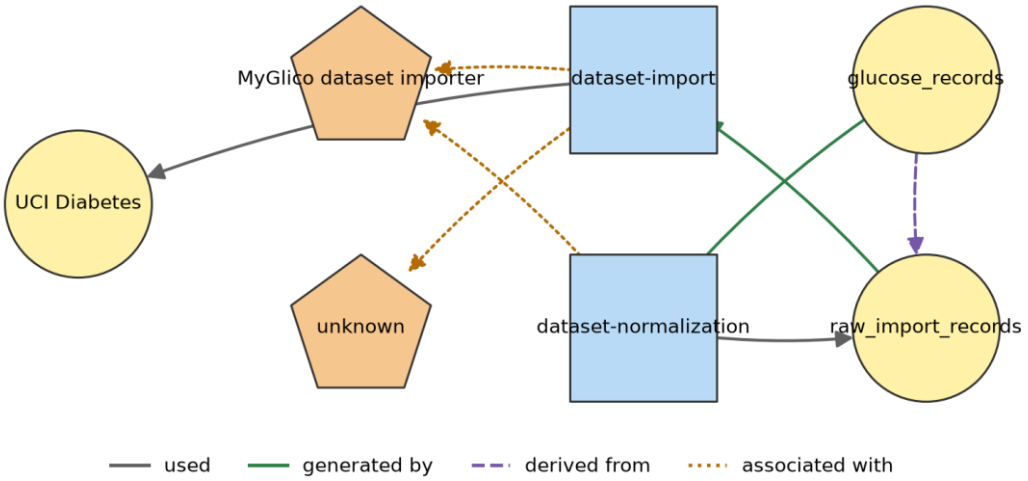


Figura 2. Proveniência da importação do dataset UCI Diabetes, com identificadores simplificados; os artefatos completos estão versionados no repositório.

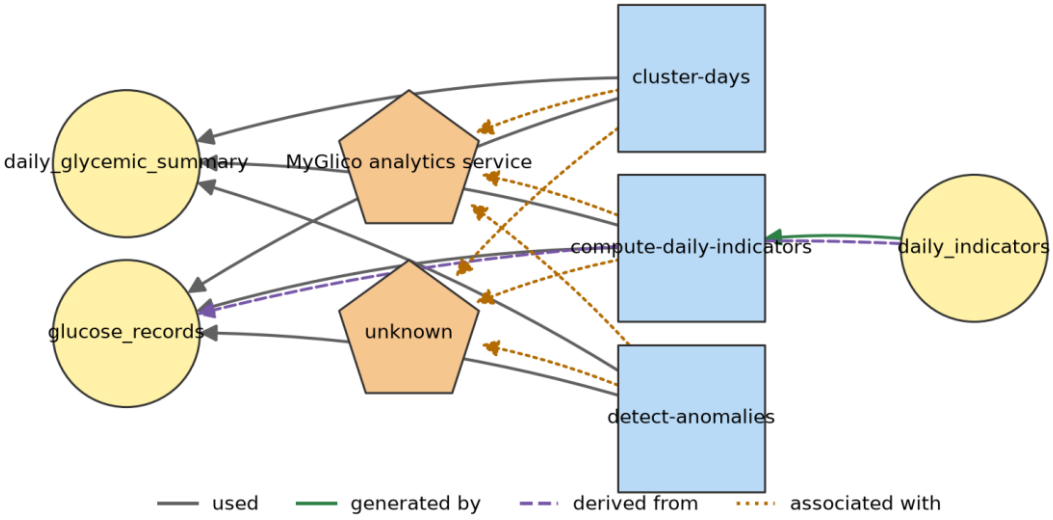


Figura 3. Proveniência da execução analítica, com identificadores simplificados; os artefatos completos estão versionados no repositório.

No *front-end*, os indicadores são apresentados em diferentes níveis de granularidade. O painel inicial exibe a quantidade de pessoas acompanhadas, registros de glicemia, dias analisados e alertas de qualidade, além de permitir busca e filtragem de pacientes por perfil em faixa, hiperglicêmico ou hipoglicêmico. A tela de detalhe do paciente apresenta um recorte temporal configurável, resumo clínico do período, distribuição percentual entre hipoglicemia, faixa e hiperglicemia, tendência glicêmica diária, curva glicêmica do dia selecionado, eventos extremos por horário, tabela de indicadores diários e eventos recentes. A navegação e o relatório clínico do paciente, exportável em PDF, oferecem suporte a múltiplos idiomas, como português, inglês e espanhol, e o relatório consolida indicadores, dias atípicos, pontos de atenção e leituras completas do período. A entrada manual de glicemia, disponível pela API, registra o dia afetado em uma fila de reanálise, sinalizando que os indicadores daquele período devem ser recalculados.

Na camada semântica, o mapeamento R2RML e a ontologia MYGV versionados no repositório permitem publicar pacientes, medições glicêmicas, registros brutos e fontes de dados como recursos RDF consultáveis por SPARQL, preservando no grafo a mesma cadeia de rastreabilidade da camada relacional. Manter o mapeamento como artefato explícito também se mostrou vantajoso: quando a triplificação é implementada apenas em código procedural, as regras de geração de RDF tendem a ficar misturadas à aplicação; no MyGlico, o R2RML pode ser inspecionado e versionado independentemente do banco e do grafo final, o que facilita a discussão do mapeamento em si e sua execução por diferentes processadores R2RML.

Os resultados indicam que a qualidade das inferências depende diretamente da qualidade, padronização e rastreabilidade dos dados de entrada: uma base inicialmente semiestruturada pôde ser transformada em indicadores organizados e auditáveis quando submetida a etapas explícitas de avaliação, normalização, proveniência e análise. O experimento apresenta limitações importantes. Ele não foi realizado com dados reais de pacientes do MyGlico, mas com o UCI Diabetes, o que restringe a validade clínica dos padrões observados. A validação concentrou-se em consistência computacional e rastreabilidade; não houve análise de sensibilidade dos parâmetros dos algoritmos, padronização das variáveis de entrada, estudo de desempenho nem avaliação dos indicadores e dos dias sinalizados por profissionais de saúde.

6. Conclusão e Trabalhos Futuros

O trabalho demonstrou que uma base glicêmica semiestruturada pode ser transformada em indicadores diários organizados e auditáveis por meio de etapas explícitas de avaliação de qualidade, normalização, análise e proveniência, preservando a rastreabilidade entre o dado original, a medição normalizada, a execução analítica e o indicador derivado. Essa rastreabilidade de ponta a ponta, somada à publicação declarativa do núcleo relacional em RDF, é a principal contribuição deste recorte e distingue o MyGlico dos aplicativos de registro glicêmico, que raramente expõem a origem e as transformações dos dados que apresentam.

O experimento também tem limites claros. A avaliação limitou-se à consistência computacional e à rastreabilidade sobre um dataset público; a utilidade clínica dos indicadores e, sobretudo, dos dias sinalizados pelo Isolation Forest e dos perfis agrupados pelo K-Means não foi verificada, e esses resultados permanecem sinais exploratórios. Por isso, o próximo passo indispensável é a validação com profissionais de saúde, comparando os indicadores e as sinalizações automáticas com a interpretação de especialistas e submetendo os parâmetros dos algoritmos, incluindo a padronização das variáveis, a contaminação e o número de grupos, a uma análise de sensibilidade.

Pretende-se também evoluir a plataforma para um ambiente de uso clínico mais completo, com cadastro de pacientes e profissionais de saúde, vinculação entre médicos e pacientes, autenticação, autorização, consentimento, revogação de acesso e demais mecanismos de governança compatíveis com a Lei Geral de Proteção de Dados. No plano técnico, a fila de reanálise já existente deverá migrar para execução assíncrona em um processo separado da API, permitindo que novos registros atualizem automaticamente os indicadores. Pretende-se ainda oferecer suporte ao registro glicêmico por meio de entrada de dados não estruturados, permitindo que anotações livres do paciente sejam convertidas em medições estruturadas e rastreáveis do diário.

Disponibilidade de Código e Dados

Todos os artefatos produzidos neste trabalho estão disponíveis publicamente no repositório **https://github.com/cale-minds/myglico**, sob a licença Apache 2.0. Isso inclui o pipeline de importação da base UCI Diabetes, a camada analítica, os artefatos de proveniência em PROV-JSON, PROV-TTL e PNG, o mapeamento R2RML, a ontologia MYGV e o *frontend* com suporte a múltiplos idiomas e relatório clínico em PDF. O repositório também está arquivado no Zenodo sob o DOI 10.5281/zenodo.21299081. Uma demonstração pública da plataforma está disponível em **https://myglico.vercel.app**.

Declaração de uso de IA generativa

Durante a preparação deste trabalho, o autor utilizou o assistente de IA generativa Claude (Anthropic) como apoio na revisão de estilo e clareza do texto, na organização do repositório público associado, incluindo licenciamento, metadados de citação e arquivamento com DOI, e na geração de scripts de importação da base UCI Diabetes, de renderização dos diagramas de proveniência e de verificação de consistência entre os números reportados e os artefatos do repositório. Nenhuma seção do artigo foi produzida integralmente por IA. Todo o conteúdo apoiado pela ferramenta foi revisado e editado pelo autor, que assume total responsabilidade pelo conteúdo do trabalho.

Referências

AMERICAN DIABETES ASSOCIATION PROFESSIONAL PRACTICE COMMITTEE FOR DIABETES*, BAJAJ, M., MCCOY, R. G., *et al.* "6. Glycemic Goals, Hypoglycemia, and Hyperglycemic Crises: Standards of Care in Diabetes—2026", **Diabetes Care**, v. 49, n. Supplement_1, p. S132–S149, 1 jan. 2026. DOI: 10.2337/dc26-S006. .

ATLA DO DIABETES DA FEDERAÇÃO INTERNACIONAL DE DIABETES,. **IDF Diabetes Atlas 2025**. **Diabetes Atlas**. [S.l: s.n.]. Disponível em: https://diabetesatlas.org/resources/idf-diabetes-atlas-2025/. Acesso em: 26 out. 2025. , 2025

BRASIL. **Lei nº 15.439, de 26 de junho de 2026**. **Diário Oficial da União**. [S.l: s.n.]. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2023-2026/2026/lei/l15439.htm. Acesso em: 13 jul. 2026. , 26 jun. 2026

CALBIMONTE, J.-P., RANVIER, J.-E., DUBOSSON, F., *et al.* "Semantic representation and processing of hypoglycemic events derived from wearable sensor data", **Journal of Ambient Intelligence and Smart Environments**, v. 9, n. 1, p. 97–109, 16 jan. 2017. DOI: 10.3233/AIS-160420. .

CONITEC, M. D. S. **RELATÓRIO DE RECOMENDAÇÃO 956 - Sistema flash de monitorização da glicose por escaneamento intermitente para o monitoramento da glicose em pacientes com diabetes mellitus tipo 1 e 2**. . [S.l: s.n.], 2024. Disponível em: https://www.gov.br/conitec/pt-br/midias/relatorios/2025/relatorio-de-recomendacao-no-956-sistema-flash-de-monitoramento. Acesso em: 25 out. 2025.

CONTRERAS, I., VEHI, J. "Artificial Intelligence for Diabetes Management and Decision Support: Literature Review", **Journal of Medical Internet Research**, v. 20, n. 5, p. e10775, 30 maio 2018. DOI: 10.2196/10775. .

CURCIN, V., MILES, S., DANGER, R., *et al.* "Implementing interoperable provenance in biomedical research", **Future Generation Computer Systems**, v. 34, p. 1–16, maio 2014. DOI: 10.1016/j.future.2013.12.001. .

CYGANIAK, R., WOOD, D., LANTHALER, M. **RDF 1.1 Concepts and Abstract Syntax**. W3C Recommendation. [S.l.], W3C, 25 fev. 2014. Disponível em: https://www.w3.org/TR/2014/REC-rdf11-concepts-20140225/. Acesso em: 4 jul. 2026.

DAS, S., SUNDARA, S., CYGANIAK, R. **R2RML: RDB to RDF Mapping Language**. W3C Recommendation. [S.l.], W3C, 27 set. 2012. Disponível em: https://www.w3.org/TR/2012/REC-r2rml-20120927/. Acesso em: 4 jul. 2026.

DE OLIVEIRA, R. F., BARBOSA, J. A. G., DE LIMA GUIMARÃES, G., *et al.* "Automonitorização glicêmica: dificuldades na realização do procedimento por pacientes com diabetes mellitus", **REME-Revista Mineira de Enfermagem**, v. 22, n. 1, 2018. Disponível em: https://periodicos.ufmg.br/index.php/reme/article/view/49685. Acesso em: 21 out. 2025.

EL-GAYAR, O., TIMSINA, P., NAWAR, N., *et al.* "Mobile Applications for Diabetes Self-Management: Status and Potential", **Journal of Diabetes Science and Technology**, v. 7, n. 1, p. 247–262, jan. 2013. DOI: 10.1177/193229681300700130. .

FLEMING, G. A., PETRIE, J. R., BERGENSTAL, R. M., *et al.* "Diabetes Digital App Technology: Benefits, Challenges, and Recommendations. A Consensus Report by the European Association for the Study of Diabetes (EASD) and the American Diabetes Association (ADA) Diabetes Technology Working Group", **Diabetes Care**, v. 43, n. 1, p. 250–260, 1 jan. 2020. DOI: 10.2337/dci19-0062. .

HARRIS, S., SEABORNE, A. **SPARQL 1.1 Query Language**. W3C Recommendation. [S.l.], W3C, 21 mar. 2013. Disponível em: https://www.w3.org/TR/2013/REC-sparql11-query-20130321/. Acesso em: 4 jul. 2026.

KAHN, M. **Diabetes UCI Machine Learning Repository**. . [S.l.], UCI Machine Learning Repository. Disponível em: https://archive.ics.uci.edu/dataset/34. Acesso em: 31 maio 2026. , 1994

LEBO, T., SAHOO, S., MCGUINNESS, D., *et al.* **PROV-O: The PROV Ontology**. W3C Recommendation. [S.l.], W3C, 30 abr. 2013. Disponível em: https://www.w3.org/TR/2013/REC-prov-o-20130430/. Acesso em: 4 jul. 2026.

"Plano de Reorganização da Atenção à Hipertensão Arterial e ao Diabetes Mellitus". **Revista de Saúde Pública**, v. 35, n. 6, p. 585–588, dez. 2001. DOI: 10.1590/S0034-89102001000600014. .

SELVAN, C., THUKRAL, A., DUTTA, D., *et al.* "Impact of Self-monitoring of Blood Glucose Log Reliability on Long-term Glycemic Outcomes in Children with Type 1

Diabetes", **Indian Journal of Endocrinology and Metabolism**, v. 21, n. 3, p. 382–386, 2017. DOI: 10.4103/ijem.IJEM_342_16. .

SILVA, S. M. J., NEGRI, J. V. A., BARRETO, T. C., *et al.* "Eficácia do monitoramento contínuo da glicose no manejo do diabetes mellitus tipo 2 em adultos", **Revista Eletrônica Acervo Médico**, v. 24, p. e18451, 15 jan. 2024. DOI: 10.25248/reamed.e18451.2024. .

WOLDAREGAY, A. Z., ÅRSAND, E., BOTSIS, T., *et al.* "Data-Driven Blood Glucose Pattern Classification and Anomalies Detection: Machine-Learning Applications in Type 1 Diabetes", **Journal of Medical Internet Research**, v. 21, n. 5, p. e11030, 1 maio 2019. DOI: 10.2196/11030. .